Архитектура: Семантическое озеро данных (Semantic Data Lake)

Концепция объединяет гибкость физического хранения файлов с возможностями логического вывода и автоматического построения корпоративного Графа знаний (Knowledge Graph).

1. Компоненты и зоны ответственности

• Хранилище (Data Lake / S3 / HDFS): Физическое хранение сырых структурированных, полуструктурированных и неструктурированных файлов (JSON, CSV, логи, документы).

• Движок CCCR (v2.4): Язык конструирования контекстно связанных рекурсивных вычислений. Выполняет декларативный семантический маппинг, транслируя древовидные структуры в базовые RDF-триплы (субъект — предикат — объект).

• Онтология OWL 2 (TBox): Формализованный набор бизнес-правил, иерархия классов, логических ограничений и взаимосвязей предметной области.

• Reasoner (Машина вывода): Движок логического вывода (например, Pellet, HermiT), который автоматически выводит новые факты из комбинации схемы онтологии и базовых триплов, а также проверяет граф на логическую непротиворечивость.

2. Сквозной пайплайн обработки данных

Слой данных	Технологический стек	Что происходит с данными	Результат семантики
RAW Layer	S3 / HDFS / Kafka	Данные загружаются «как есть» без изменения структуры из систем-источников.	Сырые изолированные файлы без бизнес-контекста.
Mapping Layer	Движок CCCR v2.4 (XQuery/SPARQL)	Парсинг и трансляция структуры через Properties, Context и выражения compute.	Базовые RDF-триплы (факты или ABox).
Ontology Layer	Protégé / OWL 2 / Turtle	Наложение бизнес-правил, аксиом, ограничений и словарей домена.	Связанная логическая схема данных (TBox).
Inference Layer	Reasoner (GraphDB / Stardog)	Вывод скрытых связей (owl:sameAs), автоматическая классификация, валидация.	Обогащенный и проверенный Граф знаний.

3. Ключевые преимущества для бизнеса

• Логический вывод новых фактов (Inference): Аналитическим системам больше не нужны сложные многоуровневые SQL-джоины. Reasoner автоматически раскрывает транзитивные и симметричные связи на основе правил логики.

• Автоматическая классификация (Classification): Объекты и сущности на лету группируются в бизнес-сегменты при изменении их свойств, разгружая инженеров данных от рутинного написания скриптов сегментации.

• Контроль качества данных (Consistency check): В отличие от обычного озера, машина вывода мгновенно обнаруживает логические противоречия и блокирует загрузку испорченных или некорректных данных на подступах к BI-системам.

• Разрешение сущностей (Entity Resolution): Использование свойств типа owl:sameAs позволяет прозрачно объединять профили клиентов или продуктов, поступающие из различных независимых систем-источников.